

## Thème Statistique

**Exercice 3** (Questions de cours (3 points)). 1. (0,5) - Le nombre d'enfants par famille.

2. (0,5) - Les familles qui viennent au parc d'attraction.

3. (0,5) - Les nombres entiers

4. (0,5) - Les 100 familles qui viennent le plus souvent. Un biais est possible car on ne prend pas les familles au hasard.

5. (1) - Diagramme en bâtons.

**Exercice 4** (Table de distribution (3,5 points)). 1. (0,5) - discrète.

2. (0,5) - qualitative.

3. (0,5) - 20.

4. (1,5) -

classe	1	2	3
effectif	4	7	9
effectif cumulé	4	11	20
fréquence (%)	20	35	45
fréquence cumulée (%)	20	55	100

5. (0,5) - 2, 2 et 3.

**Exercice 5** (Alcool et tabac (6,5 points)). 1. (1) - Moyenne empirique :  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ . Estimation :  $\bar{x} = 12.4$  donné par la fonction `mean`.

2. (1) - Variance corrigée :  $S'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ . Estimation :  $s'^2 = 5.34$  donné par la fonction `var`.

3. (2) - On estime la moyenne d'un échantillon non gaussien. On utilise l'intervalle de confiance asymptotique :

$$\left[ \bar{X} - u_{1-\alpha/2} \frac{S'}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{S'}{\sqrt{n}} \right],$$

où  $\bar{X}$  est la moyenne empirique,  $S'$  est l'écart-type corrigé et  $u_{1-\alpha/2}$  est le quantile d'ordre  $1-\alpha/2$  de la loi normale  $\mathcal{N}(0, 1)$ . Ce choix est justifié car l'échantillon est grand :  $n = 100 \geq 100$ .

4. (1) - Le calcul donne :

$$\left[ 12.4 - 1.96 \frac{2.31}{10}, 12.4 + 1.96 \frac{2.31}{10} \right] = [11.95, 12.85].$$

5. (0,5) - L'intervalle est  $[11.37, 11.83]$ , donné par la commande `t.test(X2)`.

6. (0,5) - Non. Le logiciel utilise les quantiles  $t_{n-1; 1-\alpha/2}$  de la loi de Student.

7. (0,5) - Celui de la question 5 est moins large que celui de la question 4 : cela s'explique parce que l'échantillon est plus grand. L'intersection des deux intervalles est vide : cela peut être un signe que la consommation est différente entre la population des fumeurs et celle des non fumeurs.

**Exercice 6** (Voilà les Dalton (7 points)). 1. (1) - Fréquence empirique. Estimation :  $f = 75/900 \approx 8,33\%$ .

2. (2) - On estime une proportion. On utilise l'intervalle de confiance asymptotique :

$$\left[ F - u_{1-\alpha/2} \frac{\sqrt{F(1-F)}}{\sqrt{n}}, F + u_{1-\alpha/2} \frac{\sqrt{F(1-F)}}{\sqrt{n}} \right],$$

où  $F$  est la fréquence empirique et  $u_{1-\alpha/2}$  est le quantile d'ordre  $1 - \alpha/2$  de la loi normale  $\mathcal{N}(0, 1)$ . Ce choix est justifié car l'échantillon est grand :  $n = 900 \geq 100$ .

3. (0,5) - L'intervalle est  $[0.067, 0.104]$ , donné par la commande `prop.test(75, 900)`.  
 4. (0,5) - Non, comme on l'a vu en TP.  
 5. (0,5) -  $\mathcal{H}_0 : p = p_0$  et  $\mathcal{H}_1 : p < p_0$ .  
 6. (1) - Test de conformité d'une proportion avec la statistique

$$T = \sqrt{n} \frac{F - p_0}{\sqrt{p_0(1 - p_0)}},$$

et la règle de décision (au niveau de risque  $\alpha$ ) : rejet si et seulement si  $t_{obs} < -u_{1-\alpha}$ .

7. (1) - La statistique calculée sur les données est :

$$t_{obs} = \sqrt{900} \frac{\frac{75}{900} - 0.1}{\sqrt{0.1 * 0.9}} \approx -1.67.$$

La p-valeur de notre test est  $\alpha^* = F(t_{obs}) = F(-1.67) = 1 - F(1.67) = 1 - 0.953 = 4.7\%$ . La p-valeur est inférieure à 5%, donc on rejette  $\mathcal{H}_0$  : le probabilité d'être daltonien est inférieure à 10%.

8. (0,5) - Le résultat de la dernière question semble en contradiction avec le fait que 10% appartienne à l'intervalle de confiance de la question 3 : cela vient du fait que l'on compare un intervalle de confiance (bilatéral) avec un test unilatéral.