

Thème Statistique

Exercice 1 (Questions de cours (3 points)).

1. (0,5) fonction de répartition, empirique ou théorique, variable discrète. Les valeurs en ordonnées vont de 0 à 1 (0,5).
2. (0,5) histogramme, empirique, variable continue.
3. (0,5) fonction de répartition, théorique, variable continue. Les valeurs en ordonnées vont de 0 à 1 (0,5).
4. (0,5) densité, théorique, variable continue.

Exercice 2 (Table de distribution (4 points)).

1. (0,5) Les deux variables sont qualitatives.
2. (1,5)

| Genre \ Classe | 1 | 2 | 3 | Total |
|----------------|-----|-----|-----|-------|
| Femme | 133 | 103 | 152 | 388 |
| Homme | 151 | 158 | 349 | 658 |
| Total | 284 | 261 | 501 | 1046 |

3. (0,5) La taille d'échantillon est $n = 1046$. C'est la valeur en bas à droite du tableau (c'est la somme des effectifs du tableau de contingence).
4. (a) (0,5) Elle vaut $151/1046 \approx 14.4\%$.
(b) (0,5) Elle vaut $151/658 \approx 22.9\%$.
(c) (0,5) Elle vaut $151/284 \approx 53.2\%$.

Exercice 3 (Mention au BAC (5 points)).

1. (1) La taille de l'échantillon est $n = 292 + 608 = 900$.
2. (1) Un estimateur sans biais d'une probabilité est la fréquence empirique. On en déduit l'estimation $f = 292/900 \approx 32.4\%$.
3. (2) On estime une proportion. On utilise donc l'intervalle de confiance asymptotique :

$$\left[F - u_{1-\alpha/2} \frac{\sqrt{F(1-F)}}{\sqrt{n}}, F + u_{1-\alpha/2} \frac{\sqrt{F(1-F)}}{\sqrt{n}} \right],$$

où F est la fréquence empirique et $u_{1-\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale $\mathcal{N}(0, 1)$. Ce choix est justifié car l'échantillon est grand : $n = 900 \geq 100$.

4. (0,5) L'intervalle est $[0.294, 0.356]$, donné par la commande `prop.test(292, 900)`.
5. (0,5) L'intervalle contient la valeur $0.3 = 30\%$. On ne peut donc pas dire que la probabilité de mention pour les grenoblois est différente de la valeur nationale.
6. (0,5) Non, comme on l'a vu en TP.

Exercice 4 (Soda et adolescents (8 points)).

1. (1) Moyenne empirique : $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$. Estimation : $\bar{x} = 10.4$ donné par la fonction `mean`.
2. (1) Variance corrigée : $S'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$. Estimation : $s'^2 = 4.27$ donné par la fonction `var`.

3. (2) On estime la moyenne d'un échantillon non gaussien. On utilise l'intervalle de confiance asymptotique :

$$\left[\bar{X} - u_{1-\alpha/2} \frac{S'}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{S'}{\sqrt{n}} \right],$$

où \bar{X} est la moyenne empirique, S' est l'écart-type corrigé et $u_{1-\alpha/2}$ est le quantile d'ordre $1-\alpha/2$ de la loi normale $\mathcal{N}(0,1)$. Ce choix est justifié car l'échantillon est grand : $n = 100 \geq 100$.

4. (1) Le calcul donne :

$$\left[10.4 - 1.96 \frac{2.07}{10}, 10.4 + 1.96 \frac{2.07}{10} \right] = [9.99, 10.81].$$

5. (0,5) Notons μ_1 la consommation moyenne des adolescents et μ_2 la consommation moyenne des adultes. Il faut poser $\mathcal{H}_0 : \mu_1 = \mu_2$ et $\mathcal{H}_1 : \mu_1 \neq \mu_2$.
6. (1) Comme les échantillons sont appariés (mêmes individus dix ans après), nous allons considérer l'échantillon des différences stockés dans **X1-X2**. Sur cet échantillon, nous allons utiliser un test de conformité de la moyenne de l'échantillon des différences $\mu_D = \mu_1 - \mu_2$ par rapport à la référence $\mu_0 = 0$. La statistique est

$$T = \sqrt{n} \frac{\bar{X}_D - 0}{S'_D},$$

et la règle de décision (au niveau de risque α) : rejet si et seulement si $|t_{obs}| > u_{1-\alpha/2}$.

7. (0,5) Comme nous n'avons pas fait d'hypothèse de loi normale, il faut un grand échantillon. Ce qui est vérifié ici.
8. (1) D'après les valeurs de **R**, nous avons $\bar{x}_D = 0.3$ et $s'_D = 0.965$ donc la statistique vaut

$$t = \sqrt{100} \frac{0.3}{0.965} \approx 3.11.$$

D'après l'énoncé, **pnorm(3.11)** = 0.999 donc on trouve la p-valeur $\alpha^* = 2(1 - 0.999) = 0.002$. Cette p-valeur est petite (plus petite que 5%) donc on rejette l'hypothèse nulle et on conclut que la consommation moyenne est différente entre les adolescents et les adultes.