

Intervalle de fluctuation ou intervalle de Confiance  
: Cas de la proportion

# Jeu de Pile ou Face

On joue avec une pièce juste, telle que la proba d'obtenir face soit  $p = 1/2$ .

Soit  $X_i$  la variable indicatrice de succès "obtenir face" au  $i$ -ème lancé.  $X_i$  suit une loi  $\mathcal{B}(p)$  et les  $X_i$  sont indépendantes.

Simulation de  $N = 100$  échantillons de taille  $n = 50$  et calcul des moyennes empiriques de chaque échantillon :

```
n<-50; N<-100; p=0.5 # paramètres de simulation
matrix(rbinom(n*N,1,p),ncol=n)->dataB
# un n-ech. par ligne de dataB
moys<-rowMeans(dataB) # les moyennes de chaque échantillon
length(moys) # N nombre de réalisations de  $\sum(x_i)/n$ 
```

```
## [1] 100
```

# Intervalle de fluctuation

$\bar{X}_n$  fluctue autour de son espérance  $p$  et avec une probabilité valant approximativement  $1 - \alpha$  dans l'intervalle :

$$IF(p, \alpha) = \left[ p - \sqrt{\frac{p(1-p)}{n}} u_{1-\frac{\alpha}{2}}, p + \sqrt{\frac{p(1-p)}{n}} u_{1-\frac{\alpha}{2}} \right]$$


Autrement dit

$$P(\bar{X}_n \in IF(p, \alpha)) \approx 1 - \alpha \quad \text{si} \quad np > 10 \text{ et } n(1-p) > 10$$

IF ne dépend pas de l'échantillon. C'est un **intervalle déterministe**.

# Illustration avec les N réalisations de $\bar{X}_n$

## N réalisations de la moyenne empirique d'un n-échantillon



Environ 5% des échantillons produisent un  $\bar{x}_n$  hors de l'IF donc dits non conformes au niveau de fluctuation 95%

## Amplitude de l'intervalle de fluctuation

- Pour  $p$  et  $\alpha$  fixés, l'amplitude  $2\sqrt{\frac{p(1-p)}{n}} u_{1-\frac{\alpha}{2}}$  décroît avec  $n$

On peut trouver une valeur de  $n$  minimale  $n_{min}$  pour laquelle elle est inférieure à  $a$  :

$$2\sqrt{\frac{p(1-p)}{n}} u_{1-\frac{\alpha}{2}} \leq a \iff n \geq \frac{4p(1-p)u_{1-\frac{\alpha}{2}}^2}{a^2}$$

En particulier pour le jeu de pile ou face avec une vraie pièce où  $p = 0.5$  avec  $\alpha = 0.05$  et  $a = 0.02$ ,

$n_{min} \geq a^{-2} u_{1-\frac{\alpha}{2}}^2 = (1.96)^2 (0.25) \cdot 10^4$  soit  $n_{min} = 9604$ . Pour une amplitude de 0.1 on obtient  $n_{min} = 77$  et pour une amplitude de 0.3,  $n_{min} = 26$ .

- Pour  $p$  et  $n$  fixés, lorsque  $\alpha$  augmente l'amplitude diminue. Autrement dit la précision augmente lorsque le niveau de fluctuation baisse. Et  $\alpha$  qui garantit une amplitude  $\leq a$  satisfait  $\alpha \geq 2(1 - \Phi(a\sqrt{n/(4p(1-p))}))$ . Pour  $n = 50$  et  $a = 0.02$  (précision  $\pm 1\%$ ) on devrait prendre  $\alpha \geq 88,8\%$  soit  $1 - \alpha \leq 11,2\%$ .

# Intervalle de confiance

Si  $n$  assez grand ( $np > 10$  et  $n(1 - p) > 10$ ) l'intervalle de confiance pour  $p$  de niveau de confiance approximatif  $1 - \alpha$  est donné par

$$IC(F_n, \alpha) = \left[ F_n - \sqrt{\frac{F_n(1 - F_n)}{n}} u_{1 - \frac{\alpha}{2}}, F_n + \sqrt{\frac{F_n(1 - F_n)}{n}} u_{1 - \frac{\alpha}{2}} \right]$$


Autrement dit

$$P(p \in IC(F_n, \alpha)) \approx 1 - \alpha \quad \text{si} \quad np > 10 \text{ et } n(1 - p) > 10$$

L'intervalle de confiance est un **intervalle aléatoire** qui dépend de l'échantillon et du niveau de confiance  $1 - \alpha$ .

# Calculs des IC pour les N réalisations de $\bar{X}_n$

N réalisations de l'intervalle de confiance pour  $p$  avec  $n=50$



On observe qu'environ 5% des intervalles de confiance calculés **contiennent** la valeur du paramètre  $p = 1/2$ .

## Exercice

- ▶ Refaire tourner le script en modifiant les valeurs de  $n$ ,  $N$  et  $\alpha$  dans le premier tronçon d'instruction `simulations` et observer ce qui change (les objets déterministes) et ce qui ne change pas (les objets aléatoires)
- ▶ Faire la même expérience numérique dans le modèle normal avec  $\mu = 2$  et  $\sigma = 2$  :
  - ▶ dans le tronçon `simulations` utiliser le générateur aléatoire de la loi normale `rnorm()`
  - ▶ dans le tronçon `fluctuation` adapter le calcul de l'intervalle de fluctuation au cas du modèle normal
  - ▶ dans le tronçon `confiance` adapter le calcul des intervalles de confiance pour  $\mu$  dans le cas  $\sigma$  inconnu (indication : pour calculer la variance empirique corrigée de chacun des  $N$  échantillons de taille  $n$  on peut utiliser `apply(dataG, MARGIN=1, var)` qui calcule les  $N$  variances corrigées)