

Estimation et Intervalles de confiance

Chap. 4 du polycopié

Chargés de cours

V. Léger & F. Leblanc (resp. UE)

Données : x_1, \dots, x_n

Modèle : n -échantillon X_1, \dots, X_n de X de loi dépendant d'un ou deux paramètres.

dans ce cours :

- Modèle Normal $\mathcal{N}(\mu, \sigma^2)$:
 - μ inconnu et σ connu
 - μ inconnu et σ inconnu
- Modèle de Bernoulli $\mathcal{B}(p)$ avec p inconnu

Rem : Les résultats obtenus dans le modèle normal s'étendront aux autres modèles pour n suffisamment grand grâce au TCL.

Le problème : Proposer un ou plusieurs estimateurs du ou des paramètres inconnus du modèle et en établir les propriétés pour choisir le meilleur.

Estimateur : Un estimateur de θ est une fonction connue de X_1, \dots, X_n : $T(X_1, \dots, X_n) = T_n$ (aussi noté $\hat{\theta}(X_1, \dots, X_n)$).

Exemples d'estimateurs

- pour $\mu = E(X)$: \bar{X}_n , $\min(X_i)$, X_1 , $(X_1 + X_2)/2$...
- pour $\sigma^2 = V(X)$: S_n^2 , $S_n'^2$, $X_1^2 - \bar{X}_n^2$...

Lequel choisir ?

Qualités attendues d'un estimateur :

- **Sans biais** : $E(T_n) = \theta$ (retrouve en moyenne θ)
- **De variabilité décroissante** :

$$V(T_n) \rightarrow 0 \text{ si } n \rightarrow \infty$$

- **Convergent** : sans biais et de variance tendant vers zéro avec n
- **Vocabulaire** : T_n calculé avec les données x_1, \dots, x_n produit une valeur appelée estimation de θ
- **Notations** : $\hat{\theta}$ l'estimateur de θ appliqué aux données sera parfois noté $\hat{\theta}_{calc}$ (ou plus généralement une statistique T appliquée aux données sera notée T_{calc})

Dans **tous les modèles** où la variable X est tq
 $\mu = E(X) < \infty$ et $\sigma^2 = V(X) < \infty$ les meilleurs estimateurs
de μ et σ^2 sont :

$$\hat{\mu} = \bar{X}_n \quad \text{et} \quad \hat{\sigma}^2 = S_n'^2$$

Un premier argument pour estimer μ par \bar{X}_n est la loi des
grands nombres : $\bar{X}_n \rightarrow \mu$ (on peut justifier $S_n'^2$ de manière
analogue). De plus ils sont sans biais et de variance qui tend
vers 0 avec n , en effet $\forall n$:

$$E(\bar{X}_n) = \mu \quad \text{et} \quad V(\bar{X}_n) = \frac{\sigma^2}{n}$$

$$E(S_n'^2) = \sigma^2 \quad \text{et} \quad V(S_n'^2) = \mathcal{O}\left(\frac{1}{n}\right)$$

Intervalles de confiance

Définition : On dira que $[T_1, T_2]$ est un intervalle de niveau de confiance $1 - \alpha$ pour θ si T_1 et T_2 **ne dépendent que des** X_i et éventuellement d'un paramètre connu et est tel que :

$$P(\theta \in [T_1, T_2]) = 1 - \alpha$$

Pour construire des intervalles de confiance dans le cas gaussien on utilise le résultat suivant :

Lois des estimateurs :

si X de loi $\mathcal{N}(\mu, \sigma^2)$

- \bar{X}_n suit une loi normale $\mathcal{N}(\mu, \sigma^2/n)$
- $nS_n^2/\sigma^2 = (n-1)S_n'^2/\sigma^2$ suit une loi χ_{n-1}^2

Intervalle de confiance pour μ :

- si σ^2 connue :

$$IC(\bar{X}_n, \alpha, \sigma^2) = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} u_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{n}} u_{1-\alpha/2} \right]$$

où u_p est le quantile d'ordre p d'une $\mathcal{N}(0, 1)$.

- si σ^2 inconnue :

$$IC(\bar{X}_n, \alpha) = \left[\bar{X}_n - \frac{S'_n}{\sqrt{n}} t_{n-1, 1-\alpha/2}, \bar{X}_n + \frac{S'_n}{\sqrt{n}} t_{n-1, 1-\alpha/2} \right]$$

où $t_{n-1, p}$ est le quantile d'ordre p d'une \mathcal{T}_{n-1} .

R : `t.test(x, conf.level=0.90)` fournit un IC symétrique de niveau de conf. 90%

Intervalle de confiance pour σ^2 avec μ inconnu :

$$IC(S_n^2, \alpha) = \left[\frac{nS_n^2}{z_{n-1, 1-\alpha/2}}, \frac{nS_n^2}{z_{n-1, \alpha/2}} \right]$$

Comme nS_n^2/σ^2 est une variable χ_{n-1}^2 en notant $z_{n-1,p}$ son quantile d'ordre p on a :

$$P(z_{n-1, \alpha/2} < nS_n^2/\sigma^2 < z_{n-1, 1-\alpha/2}) = 1 - \alpha$$

d'où

$$P(\sigma^2 \in IC(S_n^2, \alpha)) = 1 - \alpha$$

Si X de loi $\mathcal{B}(p)$, $\mu = E(X) = p$ et $\sigma^2 = p(1 - p)$.

\bar{X}_n représente la fréquence d'apparition du 1 dans l'échantillon notée F_n :

$$\bar{X}_n = F_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{et} \quad S_n^2 = \bar{X}_n(1 - \bar{X}_n) = F_n(1 - F_n)$$

car

$$X_i \in \{0, 1\} \implies \sum_{i=1}^n X_i^2 = \sum_{i=1}^n X_i$$

Rem : si n est suffisamment grand $S_n'^2 \approx S_n^2$ puisque $(n-1)/n \approx 1$

Modèle de Bernoulli pour p :

$$IC(F_n, \alpha) = \left[F_n - \frac{\sqrt{F_n(1 - F_n)}}{\sqrt{n}} u_{1-\alpha/2}, F_n + \frac{\sqrt{F_n(1 - F_n)}}{\sqrt{n}} u_{1-\alpha/2} \right]$$

satisfait $P(p \in I(p, \alpha)) \approx 1 - \alpha$ à condition que $np > 10$ et $n(1 - p) > 10$. IC de niveau asymptotique (ou approx.) $1 - \alpha$.

La preuve s'appuie sur le TCL qui permet de montrer que pour X de loi $\mathcal{B}(p)$: F_n suit approx. une $\mathcal{N}(p, p(1 - p)/n)$ et sur le Théorème de Slutsky pour établir ensuite que $\sqrt{n}(F_n - p)/\sqrt{F_n(1 - F_n)}$ suit approx. une loi normale centrée réduite (admis).