Normalisation d'un schéma de BD relationnelle

- Pourquoi normaliser ?
- Définition de la normalisation.
- Dépendances fonctionnelles.
- Les formes normales.

On parle de BD relationnelle 'correcte' ?

- Lorsque le schéma (composé de relations) suit des propriétés fortes:
  - ✓ chaque relation décrit un fait élémentaire avec les seuls attributs qui lui sont directement liés.
  - ✓ il n'y a pas de redondance d'information, génératrices de problèmes lors des MAJ.
  - ✓ il n'y a pas de perte d 'information
    - Personne (nom, prénom), Adresse (no, rue, ville) Qui habite où ? Impossible de répondre !
- Une relation n'est pas correcte si:
  - ✓ elle implique des répétitions au niveau de sa population
  - ✓ elle pose des problèmes lors des MAJ insertions / modifications / suppressions
- Les conditions pour qu'une relation soit correcte peuvent être définies formellement => règles de normalisation

Exemple de mauvaise relation

Livraison	(N°Fourn	AdrFourn	N°Prod	PrixProd	Qte)
	3	Grenoble	52	65	10
	22	Lyon	10	15	5
	22	Lyon	25	10	12
	3	Grenoble	25	10	5
	3	Grenoble	10	15	20

- L'adresse du fournisseur ne dépend pas du produit, il y a donc redondance !
- Le prix du produit ne dépend pas du fournisseur, idem !
- **REDONDANCES** ⇒ Anomalies de mise à jour
  - ✓ Si un fournisseur change d'adresse et qu'un seul tuple (une seule ligne) est mis à jour ⇒ **incohérence**
  - ✓ Si une nouvelle ligne est insérée pour un fournisseur connu, mais avec une adresse différente ⇒ **incohérence**

Définition de la Normalisation

- Processus de transformation d'une relation posant des problèmes lors des MAJ en plusieurs relations ne posant pas de problèmes et sans perte d'information.
- On mesure la qualité d'une relation par son degré de normalisation: 1NF, 2NF, 3NF, BCNF, etc.

Livraison (N°Fourn, AdrFourn,
N°Prod, PrixProd, Qte)

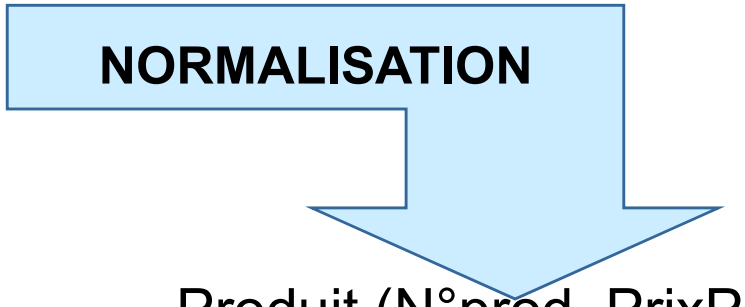

Produit (N°prod, PrixProd)

Fournisseur (N°Fourn, AdrFourn)

Livraison2 (N°Fourn, N°Prod, Qte)

Les dépendances

- Il existe 3 sortes de dépendances qui conduisent à normaliser des relations :
  - ✓ les dépendances fonctionnelles: formes 1, 2, 3 et FNBC
  - ✓ les dépendances multivaluées: forme 4
  - ✓ les dépendances de jointure: forme 5

LES DÉPENDANCES FONCTIONNELLES

Comment normaliser un schéma relationnel ?

- **Approche par décomposition :**
  - **on part d'une table contenant tous les attributs**
  - **Avec la liste des dépendances fonctionnelles**
  - **et on décompose jusqu'à ce qu'il n'y ait plus de redondances**
- Approche par synthèse :
  - à partir de l'ensemble des attributs
  - et des dépendances fonctionnelles
  - on constitue les tables

Formalisation du problème

- L'adresse d'un fournisseur ne dépend que du fournisseur, ….

  ⇒ DÉPENDANCE FONCTIONNELLE (DF)

  - soit une table T (x, y, z)
  - il existe une DF: x → y si et seulement si, dans T, à une même valeur de x correspond toujours une même valeur de y

- X → Y : X détermine Y et Y dépend de X
  - X: source de la DF, Y: cible de la DF
  - la source peut être un ensemble d'attributs:

    (nom, prénom) → adresse

Dépendance fonctionnelle élémentaire

- Dépendance fonctionnelle $X \rightarrow A$

est élémentaire si

1) A est un attribut unique

2) A n'est pas inclus dans X

3) Il n'existe pas $X' \subseteq X$ tel que $X' \rightarrow A$

- Dans la recherche des DFs, on peut se limiter sans restriction aux DFs élémentaires

Propriétés des DF (axiomes d'Amstrong)

- Réflexivité: $XY \rightarrow X$
- Augmentation: si $X \rightarrow Y$ alors $(A, X) \rightarrow Y \ \forall \ A$
  - ✓ On parle de DF non élémentaire !
  - ✓ On ne s'intéresse qu'aux DFs élémentaires non déduites qui définissent un schéma correct.
- Transitivité: si $X \rightarrow Y$ et $Y \rightarrow Z$ alors $X \rightarrow Z$
  - ➢ On parle de DF déduite !
- Union: si $X \rightarrow Y$ et $X \rightarrow Z$ alors $X \rightarrow YZ$
- Décomposition: si $X \rightarrow YZ$ alors $X \rightarrow Y$ et $X \rightarrow Z$
- Pseudo transitivité: si $X \rightarrow Y$ et $YW \rightarrow Z$ alors $XW \rightarrow Z$

Exemple de DFs

Table LESCOURS

(NOMPROF, VILLE, DEPARTEMENT,

NOMETUDIANT, AGE, COURS, NOTE)

NomProf	Ville	Département	NomEtud	Age	Cours	Note
Dupond	Lille	59	Alfred	22	Maths	12
Dupond	Lille	59	Arthur	25	Maths	5
Martin	Arras	62	Alfred	22	Anglais	18
Martin	Arras	62	Pierre	23	Anglais	11
Dupond	Lille	59	Pierre	23	Maths	13
Charles	Lille	59	Pierre	23	Français	12

1. Dépendances fonctionnelles valides :

   NOMPROF → VILLE
   NOMPROF, NOMETUDIANT → VILLE
   NOMETUDIANT → AGE

2. Dépendances fonctionnelles invalides :

   AGE → NOMETUD

3. Dépendances fonctionnelles élémentaires

   NOMPROF → VILLE
   VILLE → DEPARTEMENT

   NOMPROF → DEPARTEMENT

   NOMETUD → AGE
   NOMETUD, COURS → NOTE

   COURS → NOMPROF

Graphe Minimum des DFs (élementaires)

- ✓ Pour chaque table à normaliser,
- ✓ Il faut reconnaître les DF minimales élémentaires,
- ✓ On peut alors les représenter sous forme d'un **graphe minimum des DF** (orienté)

Exemple: T (A, B, C, D, E)

avec les DFs suivantes

$$\left.\begin{array}{l} E \rightarrow A \\ E \rightarrow B \\ E \rightarrow C \end{array}\right\} \quad (\equiv E \rightarrow A, B, C \text{ par union})$$

et $C \rightarrow D$

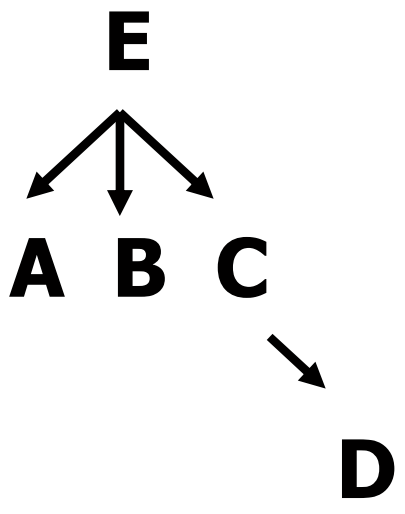

Exemple de graphe des DF

Livraison (N°fourn, adrF, N°prod, prixP, qté)

1. N°fourn → adrF

   l'adresse d'un fournisseur ne dépend que du fournisseur

2. N°prod → prixP

   le prix d 'un produit ne dépend que du produit

3. (N°fourn, N°prod) → qté

   la quantité livrée dépend du produit **et** du fournisseur

[faux: N°fourn → qté, N°prod → qté]

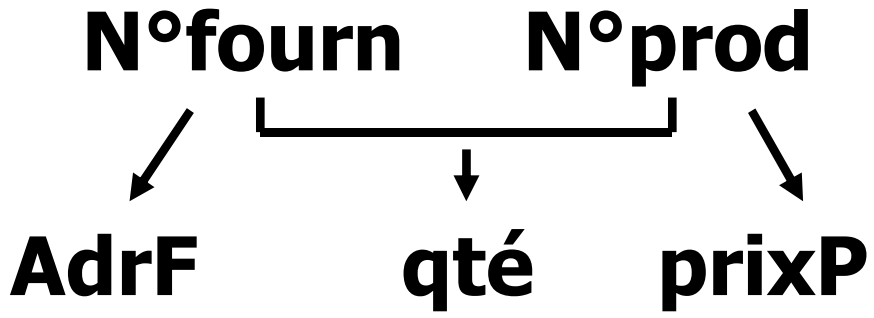

DFs et identifiants

- Le graphe minimum des DF permet de trouver les identifiants de la table
  - ✓ L'identifiant d'une table est l'ensemble (minimal) des nœuds du graphe minimum à partir desquels on peut atteindre tous les autres nœuds (via les DF),
  - ✓ Pour que ce soit faux il faudrait qu'il y ait deux tuples avec la même valeur de l'« identifiant » et des valeurs différentes pour les autres attributs, ce qui est en contradiction avec les DF, CQFD.

Exemple: T1 (A, B, C, D, <u>E</u>)

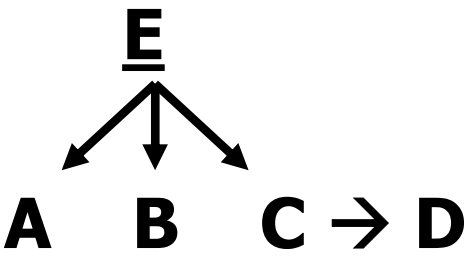

DFs et identifiants

Autre exemple: T2 (A, B, C, D, E, X, Y)

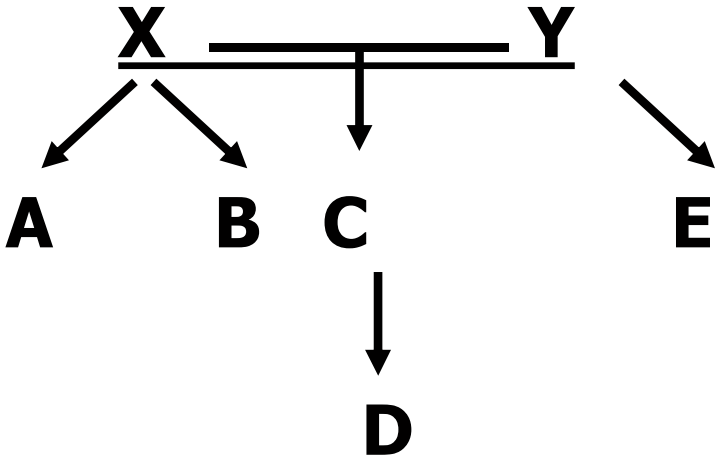

T2 (A, B, C, D, E, <u>X, Y</u>)

Normalisation

- Que faire si une table n ’est pas « normalisée » ?
  - La table doit être remplacée par un ensemble de tables (plus petites: moins d’attributs), c'est la DECOMPOSITION.
  - Comment savoir si une table est normalisée ? Il faut calculer son degré de normalisation.
- Soit une relation non satisfaisante, il faut trouver un ensemble de relations satisfaisantes qui décrive les mêmes informations.
- Pour vérifier qu’une relation est décomposable sans perte d’information:

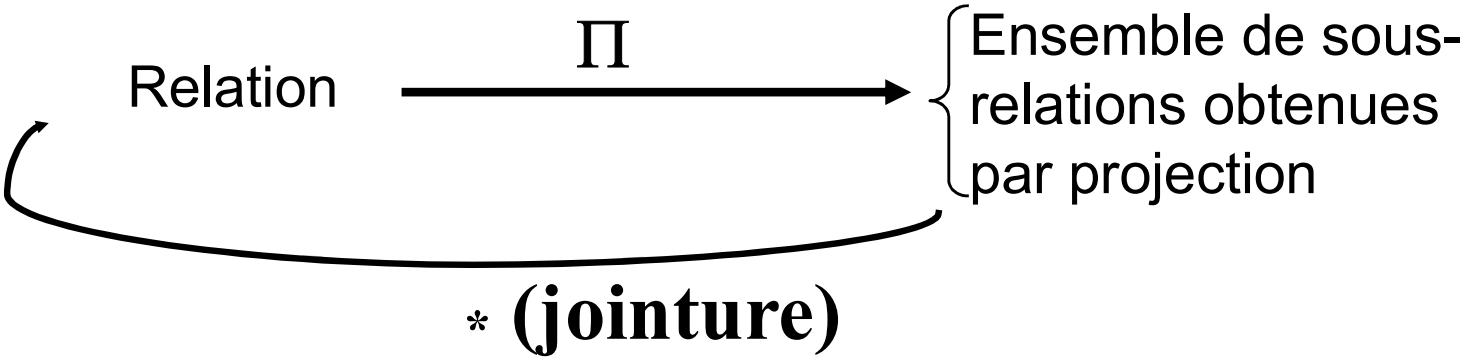

- On peut obtenir différentes décomposition, mais certaines relations normalisées peuvent être sémantiquement non significatives (pas utiles !)

Méthode pragmatique

Livraison (N°fourn, adrF, N°prod, prixP, qté)

Graphe des DF:

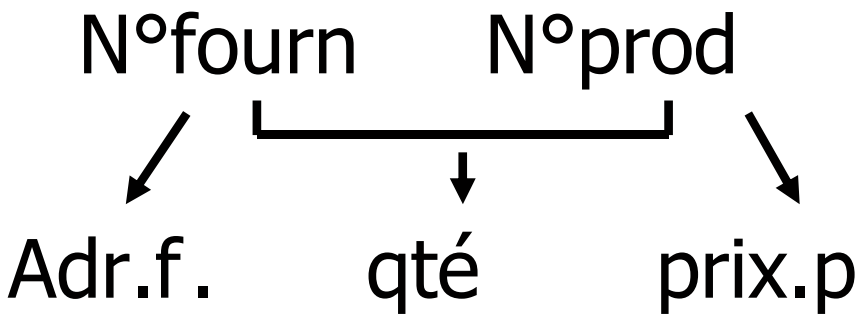

- Identifiant: N°fourn + N°prod
- Décomposition: Chaque source de DF donne naissance à une nouvelle relation.
  1. N°prod → prixP ➔ Prod (<u>N°prod</u>, prixP)
  2. N°fourn → adrF ➔ Fourn (<u>N°fourn</u>, adrF)
  3. (N°fourn, N°prod) → qté ➔ Livr. (<u>N°fourn, N°prod</u>, qté)

Méthode formelle de décomposition

- **<u>Théorème de Heath</u> : T (x, y, z) est décomposable sans perte d'information en T1 (x, y) et T2 (x, z) si x → y.**
- Application :
  1. N°fourn -> adrF ➔ T1(N°fourn, adrF) **ok**
     T2(N°fourn, N°prod, prix.p., qté)
  2. N°prod -> prixP ➔ T21(N°prod, prixP) **ok**
     T22(N°prod, N°fourn, qté)
  3. N°prod, N° fourn -> qté **ok**

Qualité d'une décomposition

Une « bonne » décomposition est une décomposition

- Sans perte d'information
  - La « recomposition » de la table à partir des « morceaux » doit redonner la table initiale
  - soit T (x, y, z) décomposée en T1 (x, y) et T2 (x, z)

    tel que: T1 = T [x, y]

    T2 = T [x, z]
  - la décomposition est sans perte d 'informations

    si et seulement si : $T = T1 * T2$

- Sans perte de DF

Exemple: bonne décomposition

T (NomEmp, adresse, poste, age)

Zoé	Grenoble	secrétaire	27
Armand	Lyon	secrétaire	32
Marie	Paris	directeur	38

T1 (NomEmp, adresse, poste)

Zoé	Grenoble	secrétaire
Armand	Lyon	secrétaire
Marie	paris	directeur

T2 (NomEmp, age)

Zoé	27
Armand	32
Marie	38

T = T1∗T2

Exemple: mauvaise décomposition

T12 (NomEmp, adresse, poste)

Zoé	Lausanne	secrétaire
Armand	Genève	secrétaire
Marie	Bienne	directeur

T22 (poste, age)

secrétaire	27
secrétaire	32
directeur	38

T12*T22 =

Zoé	Lausanne	secrétaire	27
Zoé	Lausanne	secrétaire	32
Armand	Genève	secrétaire	27
Armand	Genève	secrétaire	32
Marie	Bienne	directeur	38

$\neq$ **T**

Formes normales: 1FN

- Une relation est en **première forme normale** si chaque valeur de chaque attribut de chaque tuple est une valeur simple (tous les attributs sont simples et monovalués).
  - ✓ Tout attribut doit donc être une valeur atomique,
  - ✓ C'est normalement le cas dans le modèle relationnel,
  - ✓ Toute table est donc normalement en 1FN.

- Exemple:

  Livraison (N°fourn, adrF, N°prod, prixP, qté)

Formes normales: 1FN

Contre-exemples :

PERSONNE (NOM, PRENOMS)
Mise en 1FN :
PERSONNE (NOM, PRENOM1, PRENOM2, …, PRENOMn)

PERSONNE (NOM, PRENOM, ADRESSE)
Mise en 1FN :
PERSONNE (NOM, PRENOM, N°RUE, RUE, CODEPOSTAL, VILLE)

2ème forme normale: 2FN

Une table est en deuxième forme normale si elle est en 1FN, et si chaque attribut qui ne fait pas partie de l'identifiant dépend d'un identifiant **entier.**

- L'attribut non clé doit dépendre de la clé et pas d'une partie de la clé !
- Permet d 'éliminer les attributs qui ne décrivent pas "l'objet" traduit par la relation.

Livraison (N°fourn, adrF, N°prod, prixP, qté)

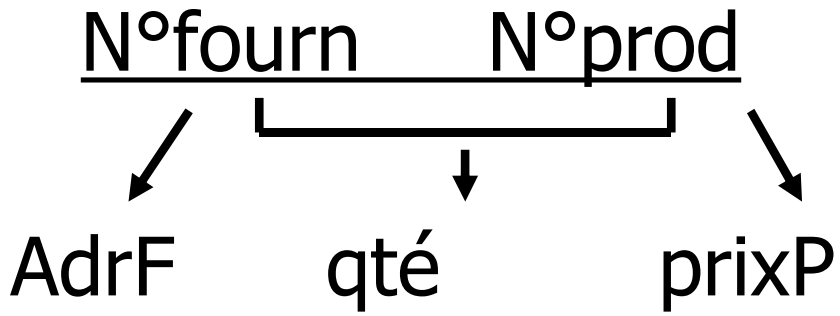

AdrF ne dépend pas de l'identifiant (N°Fourn + N°Prod),

prixP ne dépend pas de l'identifiant (N°Fourn + N°Prod),

donc ce n'est pas une 2FN.

2ème forme normale: 2FN

Exemple : LESCOURS (NOMPROF, VILLE, DEPARTEMENT, NOMETUD, AGE, COURS, NOTE)

1. **NOMPROF → VILLE**
2. **VILLE → DEPARTEMENT**
3. **NOMPROF → DEPARTEMENT**
4. **NOMETUDIANT → AGE**
5. **NOMETUDIANT, COURS → NOTE**
6. **COURS → NOMPROF**
7. **COURS -> VILLE**
8. **COURS -> DEPARTEMENT**

Faire le gaphe minimum de dépendances…
+ décomposition…

1 clé (NOMETUDIANT, COURS)

Problème car une partie de la clé (NOMETUD ou COURS) permettent d'atteindre des attributs non clés (AGE, NOMPROF, etc)

2ème forme normale: 2FN

Problème pour les attributs NOMPROF, VILLE, DEPARTEMENT et AGE

On décompose:

LESCOURS (NOMPROF, VILLE, DEPARTEMENT, NOMETUD, AGE, COURS, NOTE)

1. **NOMPROF → VILLE**
2. **VILLE → DEPARTEMENT**
3. **NOMPROF → DEPARTEMENT**
4. **NOMETUDIANT → AGE**
5. **NOMETUDIANT, COURS → NOTE**
6. **COURS → NOMPROF**
7. **COURS → VILLE**
8. **COURS → DEPARTEMENT**

en 3 relations :

LESCOURS2 (NOMETUD, COURS, NOTE)

R1 (COURS, NOMPROF, VILLE, DEPARTEMENT)

R2 (NOMETUD, AGE)

3ème forme normale: 3FN

Une table T est en 3FN si T est en 2FN et chaque attribut qui ne fait pas partie de l'identifiant dépend **directement** d'un identifiant entier.

- Permet d'éliminer des sous-relations incluses dans une relation.
- Exemple: Fournisseur (N°fourn, ville, pays)

N°fourn -> ville

ville -> pays

donc N°fourn -> pays (transitivité)

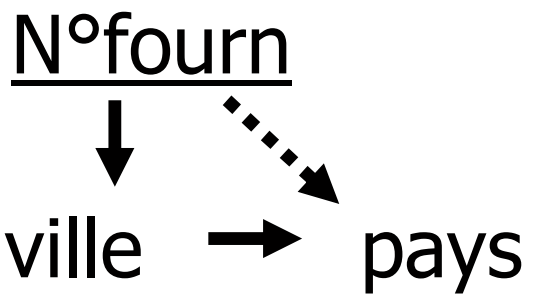

pays ne dépend pas directement d'un identifiant entier, il dépend déjà de ville, donc ce n'est pas une 3FN.
On peut donc décomposer en: F(N° fourn, ville) et G (ville, pays)

- Profondeur de l 'arbre des DF > 1 : pas en 3FN

3ème forme normale: 3FN

- Exemple avec les cours pas 3FN:

LESCOURS2 (NOMETUD, COURS, NOTE)
R1 (COURS, NOMPROF, VILLE, DEPARTEMENT)
R2 (NOMETUD, AGE)

R1 n'est pas en 3 FN
car NOMPROF →VILLE et VILLE →DEPARTEMENT
On décompose R1 en :
R11 (COURS, NOMPROF, VILLE)
R12 (VILLE, DEPARTEMENT)

Forme normale de Boyce-Codd: FNBC

Une table est en FNBC si elle est en 3FN et si toute source complète de DF est un identifiant entier.

- Généralise la 3FN aux relations avec plusieurs identifiants
- Lorsqu'un attribut non clé (mais partie de la clé) est source d'une DF ayant pour but une partie (un sous-ensemble) de la clé.

Fournisseur (N°Fourn, NomFourn, N°Prod, prix)

{(n, nf, np, p) $\in$ Fournisseur $\Leftrightarrow$ Un fournisseur de numéro n et de nom nf propose le produit np au prix p.}

On trouve deux identifiants:

(N°Fourn+N°prod) et

(NomFourn + N°prod)

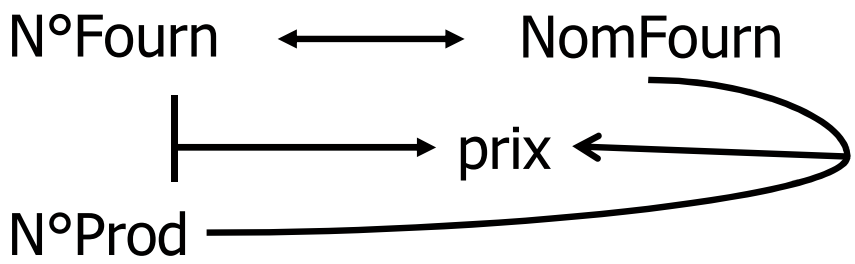

N°Fourn et NomFourn sont sources de DF, mais ne sont pas des IDs (juste chacun une partie d'un ID)

Donc 3FN mais pas en FNBC

- Le passage en FNBC n'est pas toujours possible sans perte de dépendances.
  - F1 (N°fourn, nom-fourn)
  - F2 (N°fourn, N°produit, prix) ou F 2' (nom-fourn, N°produit, prix)

FNBC: exemple qui va bien !

- Place (N°Etud, Matière, Rang)
  {(e, m, r) $\in$ Place $\Leftrightarrow$ l'étudiant de numéro e dans la matière m a obtenu le rang r.}

  N°Etud,Matière $\rightarrow$ Rang

  Rang, Matière $\rightarrow$ N°Etud

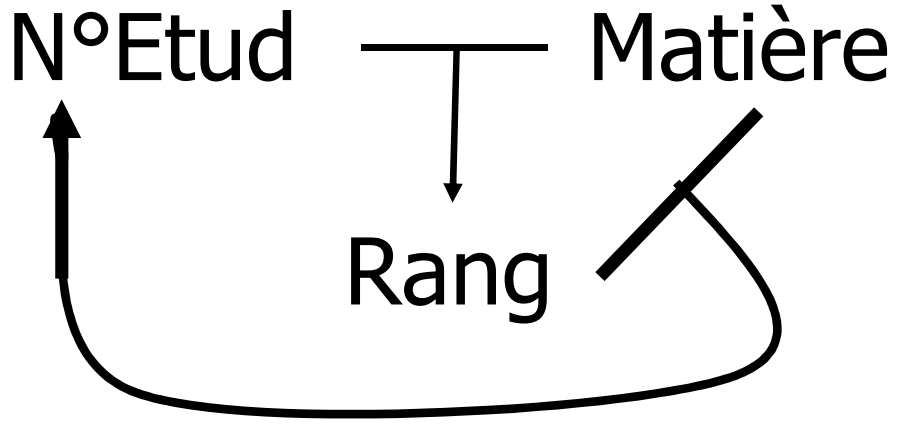

- Identifiants : 1) N°Etud + Matière

  2) Rang + Matière

- Place est en 3FN et est en FNBC.

Encore un exemple FNBC

Dans un lycée, on a relevé que :

- Pour une matière donnée et un élève donné, on a une note annuelle.

- Pour une matière donnée et un élève donné, on a un professeur.

- Un professeur enseigne une seule matière.

Exemple

Ce qui se traduit par :

ELEVE, MATIERE → PROFESSEUR

ELEVE, MATIERE → NOTE

PROFESSEUR → MATIERE

La relation RESULTAT:

(Elève, professeur) est aussi clé de la relation

(Elève, Matière, professeur, note)

Est en 3ème forme normale mais pas en F.N.B.C